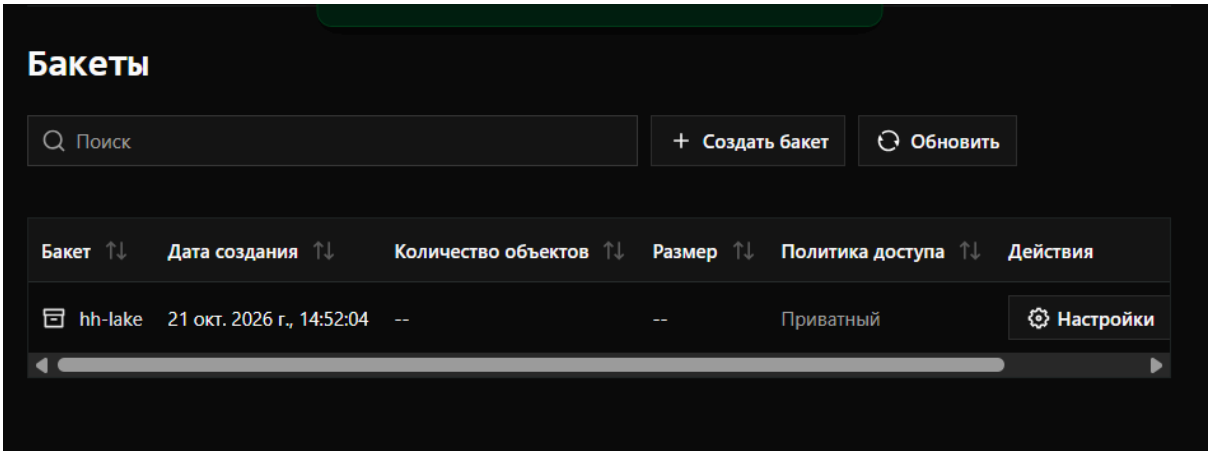
САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Дисциплина: Инженерия данных

Отчет
Домашняя работа №3
“Технология MapReduce”

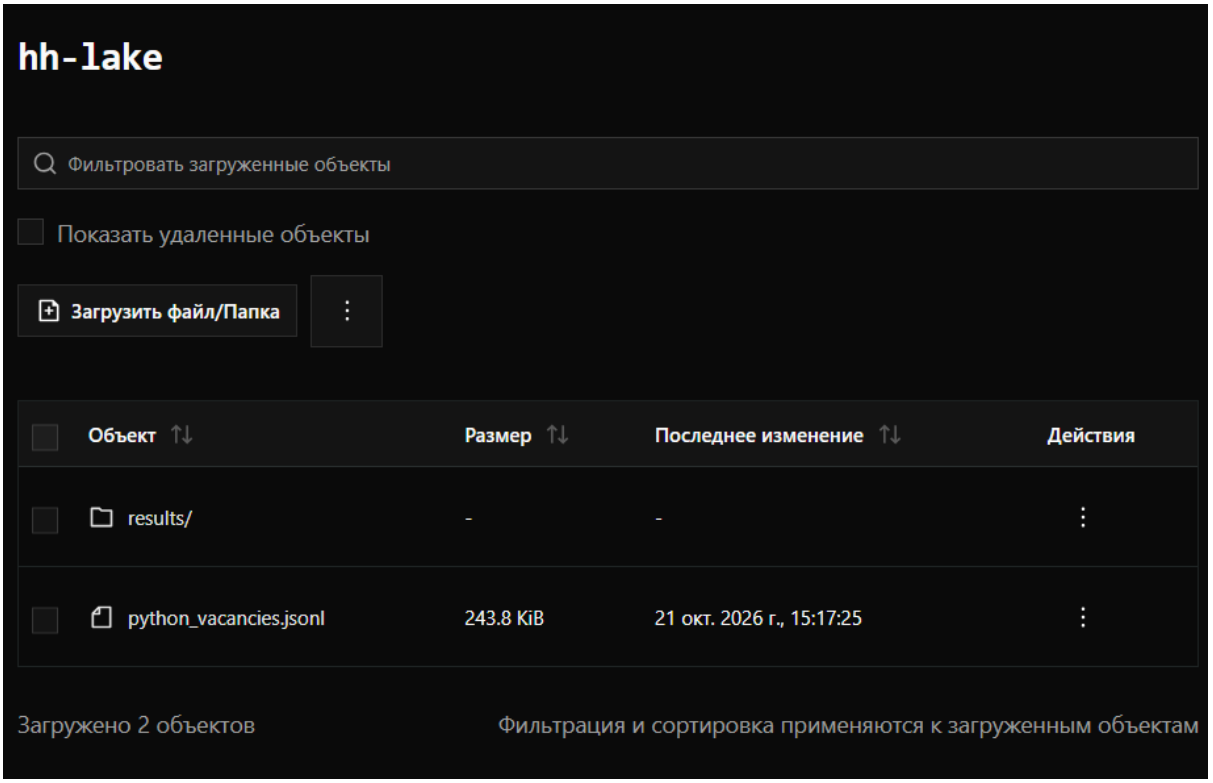
Выполнила:
Клемяционок Полина

Этап 1. Развёртывание объектного хранилища:
Развернула объектное S3-совместимое хранилище RustFS. В хранилище создан бакет с - hh-lake



Этап 2. Загрузка данных:

Использовала датасет айти вакансий. С помощью скрипта filter_data.py были отфильтрованы вакансии, в названии которых присутствкет «Python». Данные очистила и привела в формат jsonl - python_vacancies.jsonl



Этап 3. Подсчёт навыков двумя способами

mapreduce.py: скрипт подлкючается к RustFs, читает jsonl, извлекает навыки и считает частоты одиночные навыков, пар и троек
duckdb_analysis.py: sql-запрос, которые напрямую обраащется к файлу s3-хранилище, подсчитывается.
Все результаты сохранены в объектном хранилище

Этап 4. Верификация результатов:

Результаты полностью совпадают. Ну и MapReduce сработал почти в 3 раза быстрее, так как написан на чистом питоне, без расходов на инициализацию бд, но DuckDb потратил меньше оперативной памяти, так как использует векторный формат обработки данных, эффективнее расходуя озу при больших массивах, а питоне же хранит все промежуточные словари в памяти
(для получения достоверных результатов замеры времени и памяти для обоих скриптов производились по 3 раза, тут привела средний вариант)

```
PS C:\Users\pklem\OneDrive\Рабочий стол\hh_homeworh> python mapreduce.py
Уникальных навыков: 868
Уникальных пар: 9779
Уникальных троек: 48407
Время выполнения: 0.08 сек
Пиковая память: 64.45 МБ
Пропущено битых строк: 0
Сохранено в s3: results/skills.json
Сохранено в s3: results/pairs.json
Сохранено в s3: results/triples.json
```

```
PS C:\Users\pklem\OneDrive\Рабочий стол\hh_homeworh> python duckdb_analysis.
py
Уникальных навыков (DuckDB): 868
Уникальных пар (DuckDB): 9779
Уникальных троек (DuckDB): 48407
Время выполнения: 0.30 сек.
Пиковая память: 50.99 МБ
PS C:\Users\pklem\OneDrive\Рабочий стол\hh_homeworh>
```

Количество уникальных троек (48 407) превышает количество пар (9 779, так как комбинаторика: в айти-вакансиях часто указывают от 5 до 10 навыков, и количество возможных сочетаний из 3 элементов внутри такого списка математически больше, чем сочетаний из 2 элементов.
Для проверки отказоустойчивости в алгоритм добавила блок try-except, если в процессе чтения встречается поврежденная строка, маппер не завершает работу аварийно, а пропускает её

Этап 5. Анализ влияния навыков на заработную плату

По данным рассчитала базовую медианну зарплату, она получила 184.000 рублей. После определила навыки, которые сильнее всего влияют на изменение медианы

```
PS C:\Users\pklem\OneDrive\Рабочий стол\hh_homeworh> python salary_analysis.
py

базовая медианная зарплата: 184000 рублей
('aiohttp', 'fastapi'): медиана 350000 (прибавка +166000), вакансий: 6
('asyncio', 'fastapi'): медиана 350000 (прибавка +166000), вакансий: 3
('fastapi', 'kubernetes'): медиана 340000 (прибавка +156000), вакансий: 3
('fastapi', 'rabbitmq'): медиана 340000 (прибавка +156000), вакансий: 5
('aiohttp', 'asyncio'): медиана 325000 (прибавка +141000), вакансий: 4
('html', 'javascript'): медиана 70000 (падение -114000), вакансий: 7
('css', 'git'): медиана 70000 (падение -114000), вакансий: 7
('css', 'flask'): медиана 70000 (падение -114000), вакансий: 3
('java', 'python'): медиана 60000 (падение -124000), вакансий: 3
('java', 'sql'): медиана 60000 (падение -124000), вакансий: 3

медианы базовых навыков:
  медиана только за 'javascript': 160000 руб.
  медиана только за 'html': 150000 руб.
  медиана только за 'java': 60000 руб.
  медиана только за 'python': 175000 руб.

Регион: Москва
  кол-во вакансий с зарплатой: 159
  медианная зарплата: 205000 руб.
  самый частый навык: python (139 раз)

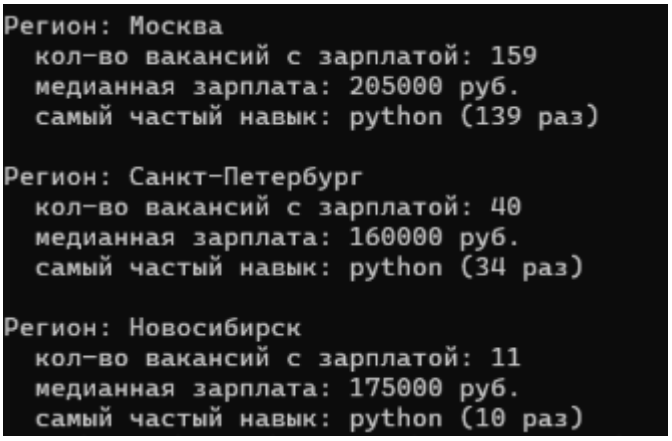
Регион: Санкт-Петербург
  кол-во вакансий с зарплатой: 40
  медианная зарплата: 160000 руб.
  самый частый навык: python (34 раз)

Регион: Новосибирск
  кол-во вакансий с зарплатой: 11
  медианная зарплата: 175000 руб.
  самый частый навык: python (10 раз)
```

Повышаю зарплату: асинхронные фреймворки aiohttp + fastapi, asyncio + fastapi, и связка fastapi + kubernetes. Медиана в таких вакансиях достигает 350.000 рублей. Можно сказать, что повышение связано с тем, что данные технологии используются в высоконагруженных микросервисах, где требуются специалисты с высокой квалификации

Понижают зарплату: базовые навыки веб-разработки (html + javascript, css + git) и связка java + python. Медиана падает до 60.000 - 70.000 рублей. Если посмотреть на медина базовых навыков по отдельности, то javascript стоит 160.000 рублей, а html 150.000 рублей, но в паре они дают сильное падение до 70.000 рублей. Это связано с тем, что HTML+JavaScript часто встречается в вакансиях начинающих фронтендеров или верстальщиков

Этап 6. Региональный анализ



В Москве, ожидаемо, самый высокий уровень зарплаты, но Новосибирск обошел СПб по медианной. Скорее всего, связано с тем, что в Новосибирске находятся офисы бигтехов, либо с высоким процентом удаленных вакансий.

Этап 7. Оформление результатов

гитхаб - https://github.com/kleeeeem/hw3_data-engineering_hh